Klasifikasi Preferensi Pembayaran QRIS dan Tunai Berbasis Karakteristik Konsumen Menggunakan Metode SVM

Rezki Alya Pasrun*[1]
[1]Teknik Informatika, Fakultas Teknik, Universitas Halu Oleo
e-mail: *[1]rezkialya0909@gmail.com

Abstrak

Perkembangan sistem pembayaran digital mendorong perubahan perilaku dan preferensi konsumen dalam melakukan transaksi. Salah satu inovasi pembayaran non-tunai di Indonesia adalah Quick Response Code Indonesian Standard (QRIS) yang menawarkan kemudahan, kecepatan, dan efisiensi transaksi. Namun, preferensi konsumen dalam memilih metode pembayaran QRIS atau tunai dipengaruhi oleh berbagai karakteristik individu dan persepsi penggunaan. Penelitian ini bertujuan untuk mengklasifikasikan preferensi pembayaran QRIS dan tunai berdasarkan karakteristik konsumen menggunakan metode Support Vector Machine (SVM). Dataset yang digunakan terdiri dari 600 data responden hasil kuesioner yang mencakup aspek demografis, perilaku digital, serta persepsi terhadap penggunaan QRIS. Proses penelitian meliputi tahap pembersihan data, normalisasi menggunakan StandardScaler, pembagian data latih dan data uji, serta pelatihan model SVM dengan kernel Radial Basis Function (RBF). Optimasi hyperparameter dilakukan menggunakan GridSearchCV untuk memperoleh parameter terbaik. Hasil penelitian menunjukkan bahwa model SVM mampu mencapai akurasi sebesar 0,75 pada data uji. Selain itu, analisis feature ablation dilakukan untuk mengidentifikasi kontribusi masing-masing fitur terhadap performa model. Hasil klasifikasi ini diharapkan dapat memberikan gambaran pola preferensi pembayaran konsumen serta menjadi dasar analisis perilaku pembayaran digital di masyarakat.\.

Kata kunci—QRIS, Preferensi Pembayaran Digital, Support Vector Machine, Perilaku Konsumen

Abstract

The development of digital payment systems has led to significant changes in consumer behavior and payment preferences. One of the non-cash payment innovations in Indonesia is the Quick Response Code Indonesian Standard (QRIS), which offers convenience, speed, and transaction efficiency. However, consumer preferences in choosing between QRIS and cash payments are influenced by various individual characteristics and usage perceptions. This study aims to classify payment preferences between QRIS and cash based on consumer characteristics using the Support Vector Machine (SVM) method. The dataset consists of 600 respondent records collected through a questionnaire, covering demographic factors, digital behavior, and perceptions of QRIS usage. The research process includes data cleaning, feature normalization using StandardScaler, train–test data splitting, and SVM model training with a Radial Basis Function (RBF) kernel. Hyperparameter optimization is performed using GridSearchCV to obtain the best parameter configuration. The results show that the SVM model achieves an accuracy of 0.75 on the test data. Furthermore, feature ablation analysis is conducted to evaluate the contribution of each feature to the classification performance. The findings are expected to provide insights into consumer payment preference patterns and support further analysis of digital payment behavior.

Keywords—QRIS, Digital Payment Preference, Support Vector Machine, Consumer Behavior

1. PENDAHULUAN

Perkembangan teknologi informasi dan komunikasi telah membawa perubahan signifikan dalam berbagai aspek kehidupan masyarakat, termasuk pada sistem pembayaran. Pemanfaatan teknologi dalam layanan keuangan atau *financial technology* (fintech) mendorong pergeseran metode transaksi dari pembayaran berbasis tunai menuju sistem pembayaran digital yang lebih efisien, cepat, dan praktis. Transformasi ini tidak hanya mengubah cara masyarakat bertransaksi, tetapi juga membentuk pola perilaku dan preferensi konsumen dalam memilih metode pembayaran yang digunakan sehari-hari.

Seiring dengan perkembangan fintech, sistem pembayaran digital di Indonesia terus mengalami peningkatan dan standarisasi. Bank Indonesia memperkenalkan *Quick Response Code Indonesian Standard* (QRIS) sebagai standar nasional pembayaran berbasis kode QR yang bertujuan menciptakan interoperabilitas antar penyedia jasa sistem pembayaran serta meningkatkan efisiensi transaksi masyarakat. Kehadiran QRIS memungkinkan konsumen melakukan transaksi non-tunai secara praktis menggunakan berbagai aplikasi dompet digital dan *mobile banking* [1].

Dalam praktiknya, penggunaan QRIS tidak terlepas dari preferensi konsumen yang beragam. Sejumlah penelitian menunjukkan bahwa preferensi konsumen terhadap penggunaan QRIS dipengaruhi oleh berbagai faktor, seperti persepsi kemudahan penggunaan, keamanan, manfaat, serta pengalaman penggunaan dalam transaksi sehari-hari. Saputri [2] mengemukakan bahwa faktor persepsi kemudahan dan kepercayaan memiliki peran penting dalam membentuk preferensi konsumen terhadap penggunaan QRIS sebagai alat pembayaran digital. Selain itu, kendala teknis seperti kestabilan jaringan internet dan kegagalan pemindaian QR juga turut memengaruhi kenyamanan pengguna dalam bertransaksi [3].

Dalam konteks akademik, sebagian besar penelitian terkait QRIS masih menggunakan pendekatan deskriptif atau model adopsi teknologi seperti *Technology Acceptance Model* (TAM) dan *Unified Theory of Acceptance and Use of Technology* (UTAUT) untuk menganalisis faktor-faktor yang memengaruhi niat dan perilaku penggunaan pembayaran digital. Pendekatan tersebut umumnya berfokus pada hubungan antar variabel, namun belum banyak dimanfaatkan untuk membangun model klasifikasi preferensi konsumen secara komputasional.

Padahal, data karakteristik konsumen yang mencakup aspek demografis, perilaku digital, persepsi, serta pengalaman penggunaan pembayaran digital memiliki potensi untuk diolah menggunakan metode *machine learning* [4]. Algoritma klasifikasi seperti *Support Vector Machine* (SVM) mampu mempelajari pola dari data multivariat dan digunakan untuk mengklasifikasikan preferensi konsumen ke dalam kategori tertentu secara lebih sistematis dan objektif [5].

Oleh karena itu, penelitian ini bertujuan untuk mengembangkan model klasifikasi preferensi pembayaran QRIS dan tunai berbasis karakteristik konsumen menggunakan algoritma SVM. Penelitian ini diharapkan dapat memberikan kontribusi dalam bidang teknik informatika, khususnya pada penerapan *machine learning* untuk analisis preferensi pembayaran digital, serta menyediakan pemetaan preferensi konsumen yang dapat digunakan sebagai informasi pendukung dalam memahami keragaman perilaku pembayaran di Masyarakat.

2. METODE PENELITIAN

Penelitian ini menggunakan pendekatan kuantitatif dengan menerapkan metode *machine learning* untuk mengklasifikasikan preferensi pembayaran QRIS dan tunai berdasarkan karakteristik konsumen. Tahapan penelitian disusun secara sistematis mulai dari pengumpulan dan persiapan data, proses prapemrosesan, pembangunan model klasifikasi, hingga evaluasi kinerja model dan analisis lanjutan. Diagram alur proses klasifikasi yang digunakan dalam penelitian ini ditunjukkan pada Gambar X, yang

menggambarkan keseluruhan tahapan penelitian secara ringkas dan terstruktur.

Pada Gambar 1 menunjukkan mekanisme yang digunakan dalam penelitian

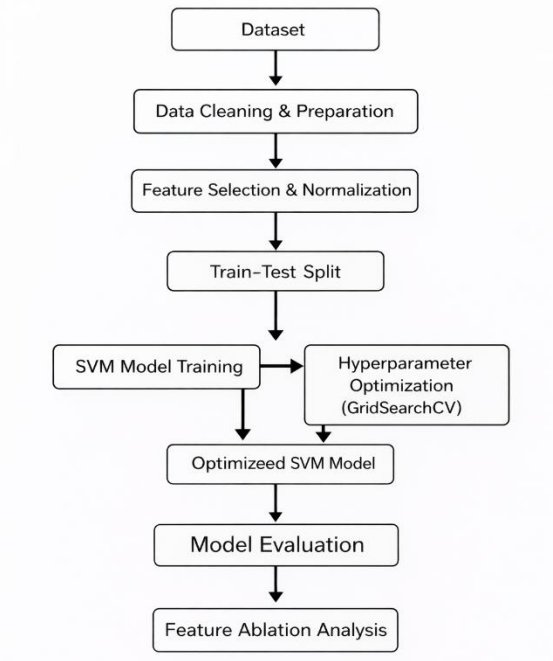

Gambar 1 Diagram Proses Klasifikasi

2.1 Dataset

.

Tabel 1. Karakteristik Data

no	Nama fitur	Tipe
1	Age	Ordinal
2	monthly_income	Ordinal
3	smartphone_readiness	Ordinal
4	internet_stability	Ordinal
5	fintech_usage_frequency	Ordinal
6	qris_transaction_speed	Ordinal
7	qris_security	Ordinal
8	qris_failure_frequency	Ordinal
9	transaction_nominal	Ordinal
10	cash_spending_faster	Ordinal
11	expense_control_qris	Ordinal
12	no_cash_comfort	Ordinal
13	cash_security_risk	Ordinal
14	qris_signal_or_scan_issue	Ordinal

2.2 Support Vector Machine (SVM)

Support Vector Machine merupakan metode *supervised learning* yang mencari hyperplane optimal untuk memisahkan kelas, dan mampu menangani data non-linear dengan *kernel trick* untuk memproyeksikannya ke ruang berdimensi lebih tinggi [6]. fungsi keputusan SVM dinyatakan sebagai:

$$f(x) = sign(\omega \cdot x + b) \qquad (1)$$

Namun, karena data karakteristik konsumen bersifat non-linear, penelitian ini menggunakan SVM dengan pendekatan *kernel trick*. Fungsi keputusan SVM dengan kernel dinyatakan sebagai:

$$K(x_i, x_j) = \exp\left(-\gamma||x_i - x_j||\right) \qquad (2)$$

Penggunaan kernel RBF bertujuan untuk menangkap pola non-linear pada data. Parameter Cdan γdioptimasi menggunakan GridSearchCV untuk memperoleh performa model yang optimal.

2. 3 Pembersihan dan Persiapan Data

Tahap pembersihan data dilakukan dengan menghapus kolom yang seluruh nilainya kosong serta kolom yang mengandung nilai *NaN* yang berpotensi mengganggu proses normalisasi data. Beberapa kolom yang tidak relevan secara eksplisit dihapus agar dataset hanya berisi atribut yang valid dan siap digunakan pada tahap pemodelan..

2. 4 Pemisahan Fitur dan Label

Dataset dipisahkan menjadi variabel fitur (X) dan variabel target (y). Kolom Label ditetapkan sebagai variabel target yang merepresentasikan preferensi pembayaran, sedangkan kolom lainnya digunakan sebagai variabel fitur. Selanjutnya, data dibagi menjadi data latih sebesar 80% dan data uji sebesar 20%.

2. 5 Normalisasi Fitur

Normalisasi fitur dilakukan menggunakan metode StandardScaler untuk mengubah nilai fitur sehingga memiliki rata-rata 0 dan standar deviasi 1. Proses ini bertujuan untuk menyamakan skala data sebelum diterapkan pada algoritma Support Vector Machine.

2. 6 Pelatihan Model SVM

Model Support Vector Machine dilatih menggunakan kernel Radial Basis Function (RBF) dengan parameter default. Proses

pelatihan dilakukan pada data latih yang telah dinormalisasi, kemudian model diuji menggunakan data uji.

2. 7 Optimasi Hyperparameter

Tahapan ini mencakup parameter tuning yang bertujuan untuk memperoleh konfigurasi parameter terbaik sehingga dapat meningkatkan dan mengukur akurasi model klasifikasi [7]. Optimasi hyperparameter dilakukan menggunakan metode GridSearchCV dengan 5-fold cross-validation. Parameter yang dioptimasi meliputi nilai C dan gamma pada kernel RBF. Proses ini bertujuan untuk memperoleh kombinasi parameter terbaik berdasarkan data latih.

2. 8 Pelatihan Model dengan Parameter Terbaik

Optimasi hyperparameter dilakukan menggunakan metode GridSearchCV dengan 5-fold cross-validation. Parameter yang dioptimasi meliputi nilai C dan gamma pada kernel RBF. Proses ini bertujuan untuk memperoleh kombinasi parameter terbaik berdasarkan data latih.

2. 9 Evaluasi Model

Evaluasi model dilakukan menggunakan metrik akurasi dan classification report untuk menilai kinerja model klasifikasi pada data uji.

2. 10 Feature Ablation

Feature ablation dilakukan untuk menganalisis kontribusi masing-masing fitur terhadap performa model klasifikasi. Metode ini dilakukan dengan menghilangkan satu fitur secara bergantian dari dataset, kemudian mengevaluasi kembali kinerja model menggunakan parameter terbaik yang telah diperoleh. Perubahan nilai akurasi digunakan sebagai indikator tingkat pengaruh fitur terhadap hasil klasifikasi.

3. HASIL DAN PEMBAHASAN

Model klasifikasi pada penelitian ini dibangun menggunakan algoritma Support Vector Machine (SVM) sebagai model dasar (*baseline*). SVM diinisialisasi dengan kernel Radial Basis Function (RBF) dan parameter default karena kernel ini mampu menangani pola data non-linear pada karakteristik konsumen. Dataset yang digunakan terdiri dari 600 data responden hasil kuesioner preferensi pembayaran QRIS dan tunai.

Model klasifikasi dibangun menggunakan algoritma Support Vector Machine (SVM) dengan kernel Radial Basis Function (RBF) dan parameter default sebagai model baseline. Dataset terdiri dari 600 data responden yang dibagi menggunakan skema train–test split 80:20. Hasil evaluasi model SVM sebelum dilakukan hyperparameter tuning ditunjukkan pada Gambar 1, dengan nilai akurasi sebesar 0,75 pada data uji.

Classification Report:

	precision	recall	f1-score	support
0	0.70	0.75	0.73	53
1	0.79	0.75	0.77	67
accuracy			0.75	120
macro avg	0.75	0.75	0.75	120
weighted avg	0.75	0.75	0.75	120

Gambar 2 Tingkat Akurasi setelah *training*

Selanjutnya, dilakukan proses cross-validation dan hyperparameter tuning menggunakan metode Grid Search dengan skema 5-fold cross-validation pada data latih untuk memperoleh parameter yang optimal. Gambar 2 menunjukkan hasil evaluasi setelah dilakukan *hyperparameter tuning*.

Classification Report:

	precision	recall	f1-score	support
0	0.69	0.75	0.72	53
1	0.79	0.73	0.76	67
accuracy			0.74	120
macro avg	0.74	0.74	0.74	120
weighted avg	0.75	0.74	0.74	120

Gambar 2 Tingkat Akurasi setelah *training*

Berdasarkan hasil evaluasi setelah dilakukan hyperparameter tuning, model SVM memperoleh nilai akurasi sebesar 0,7417 pada data uji. Meskipun nilai akurasi sedikit lebih rendah dibandingkan model baseline, hasil ini menunjukkan bahwa model memiliki kemampuan generalisasi yang lebih stabil dan mengurangi risiko overfitting.

Setelah diperoleh model terbaik berdasarkan hasil evaluasi akurasi dan metrik kinerja lainnya, dilakukan analisis *feature ablation* untuk mengetahui kontribusi masing-masing fitur terhadap performa model. Feature ablation dilakukan dengan menghilangkan satu fitur secara bergantian dari dataset, kemudian mengevaluasi kembali kinerja model menggunakan konfigurasi parameter terbaik. Perubahan nilai akurasi yang terjadi digunakan

sebagai indikator tingkat pengaruh fitur terhadap hasil klasifikasi. Hasil analisis feature ablation ditunjukkan pada Gambar 3.

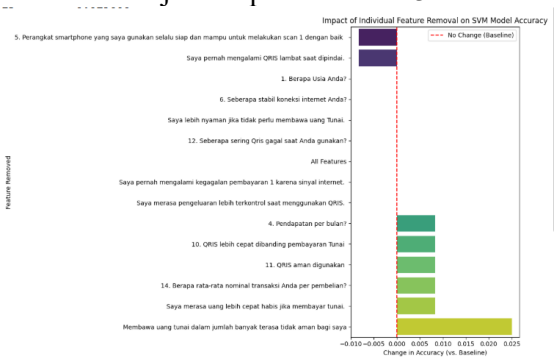

Gambar 3 Hasil feature ablation pada model SVM terhadap perubahan akurasi.

Gambar 3 menunjukkan bahwa fitur frekuensi penggunaan aplikasi keuangan memberikan pengaruh terbesar terhadap akurasi model, sedangkan beberapa fitur lain menunjukkan kontribusi yang relatif rendah atau cenderung bersifat noise. Hal ini mengindikasikan bahwa preferensi pembayaran QRIS lebih dipengaruhi oleh pengalaman dan kebiasaan penggunaan teknologi.

4. KESIMPULAN

1. Algoritma Support Vector Machine (SVM) mampu mengklasifikasikan preferensi pembayaran QRIS dan tunai berdasarkan karakteristik konsumen dengan akurasi **0,75**.
2. Proses tuning parameter menghasilkan akurasi 0,7417, yang menunjukkan bahwa tuning tidak selalu meningkatkan performa model
3. Hasil penelitian menunjukkan bahwa karakteristik konsumen memiliki pengaruh terhadap preferensi metode pembayaran, namun masih terdapat kesalahan klasifikasi yang menunjukkan keterbatasan model.

5. SARAN

Penelitian selanjutnya diharapkan dapat menggunakan jumlah data yang lebih besar dan beragam untuk meningkatkan kualitas dan validitas hasil analisis. Data yang lebih banyak akan membantu model dalam mengenali pola preferensi pembayaran secara lebih akurat.

Selain itu, keberagaman data yang mencakup berbagai tipe konsumen, seperti perbedaan usia, tingkat pendapatan, dan latar belakang sosial, diharapkan mampu menghasilkan model klasifikasi yang lebih representatif dan dapat diterapkan secara luas pada kondisi nyata.

UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih kepada pihak institusi dan seluruh responden yang telah berpartisipasi sehingga penelitian ini dapat diselesaikan dengan baik.

DAFTAR PUSTAKA

[1] "Quick Response Code Indonesian Standard (QRIS)." Accessed: Dec. 30, 2025. [Online]. Available: https://www.bi.go.id/en/fungsi-utama/sistem-pembayaran/ritel/kanal-layanan/qris/default.aspx

[2] O. B. Saputri, "Preferensi konsumen dalam menggunakan quick response code indonesia standard (qris) sebagai alat pembayaran digital," *Kinerja J. Ekon. Dan Manaj.*, vol. 17, no. 2, pp. 237–247, 2020.

[3] F. Emiliyana, S. Asakdiyah, and A. Sutanto, "ANALISIS PREFERENSI MAHASISWA DALAM MENGGUNAKAN QRIS SEBAGAI TEKNOLOGI PEMBAYARAN," *J. Perilaku Dan Strategi Bisnis*, vol. 12, no. 1, pp. 75–93, 2024.

[4] A. I. Sari, E. S. Wahyuni, and K. Elwardah, "PENGARUH KEMUDAHAN, KEMANFAATAN DAN KEAMANAN TERHADAP PREFERENSI KONSUMEN DALAM MENGGUNAKAN QRIS SEBAGAI SISTEM PEMBAYARAN NON TUNAI," *Juremi J. Ris. Ekon.*, vol. 4, no. 5, pp. 1077–1088, 2025.

[5] A. Bimo, W. R. Nursitasari, and N. A. Septiani, "Analisis Sentimen Masyarakat Terhadap Penggunaan Qris Pada Platform Gojek Menggunakan Metode Naives Bayes Class," *J. Komput. Antartika*, vol. 3, no. 3, pp. 127–135, 2025.

[6] F. S. Jumeilah, "Penerapan Support Vector Machine (SVM) untuk Pengkategorian Penelitian," *J. RESTI Rekayasa Sist. Dan Teknol. Inf.*, vol. 1, no. 1, pp. 19–25, 2017.

[7] I. G. T. Isa and B. Junedi, "Hyperparameter tuning epoch dalam meningkatkan akurasi data latih dan data validasi pada citra

pengendara," *Pros. Sains Nas. Dan Teknol.*, vol. 12, no. 1, pp. 231–237, 2022.